

Construction frugale de graphes de connaissances par LLM locaux : pipeline zero-shot, self-consistency et sagesse des foules artificielles

Pierre Jourlin

Avignon Université, Laboratoire d'Informatique d'Avignon (LIA)

`pierre.jourlin@univ-avignon.fr`

Avril 2026

Résumé

Cet article présente une étude empirique d'un pipeline zero-shot multi-modèle pour la construction et l'exploitation de graphes de connaissances, exécuté exclusivement en inférence locale sur matériel grand public. Nous proposons un cadre d'évaluation reproductible intégrant quatre benchmarks (DocRED, WebQuestionsSP, HotpotQA, RAGAS) dans un pipeline automatisé. Sur 500 relations documentaires, notre système atteint un F1 de $0,70 \pm 0,04$ (Intervalle de Confiance — IC 95 %) en zero-shot, contre 0,80 pour DREEM supervisé. La traduction texte-en-requête obtient une exactitude de $0,80 \pm 0,06$ sur 200 échantillons. Le raisonnement multi-hop atteint une correspondance exacte (Exact Match, EM) de 0,46 sur 500 questions HotpotQA, avec une fidélité RAGAS de $0,96 \pm 0,04$ sur 50 échantillons.

Au-delà du pipeline, nous étudions les mécanismes de diversité pour le raisonnement multi-hop difficile. Sur 181 questions insolubles à température nulle, la self-consistency ($k=5$, $T=0,7$) récupère jusqu'à 23 % d'EM avec un unique modèle à mélange d'experts (Mixture of Experts, MoE), mais l'oracle inter-modèles (3 architectures $\times$ 5 échantillons) atteint 46,4 %. Nous mettons en évidence un *paradoxe de l'accord* : un fort consensus entre échantillons signale une hallucination collective plutôt qu'une réponse fiable, en écho aux travaux de Moussa"Id et al. sur la sagesse des foules.

En extension au pipeline complet (500 questions), la self-consistency ($k=3$) porte l'EM de 0,46 à 0,48 [0,44 ; 0,52]. Un mécanisme de *cascade par routage de confiance* (phi-4 $\rightarrow$ GPT-OSS, $k=5$) atteint **EM=0,55** [0,51 ; 0,59], le meilleur résultat obtenu, avec 45,4 % des questions reroutées. Enfin, nous montrons que l'ingénierie de prompts V3 appliquée à d'autres modèles ne reproduit pas les gains observés avec Gemma-4, confirmant l'interaction spécifique prompt $\times$ modèle.

L'ensemble s'exécute en ~ 5 h sur une seule RTX 3090, sans aucun entraînement, pour une empreinte carbone estimée à 0,09 kg CO₂eq.

Mots-clés : graphe de connaissances, extraction de relations, IA frugale, zero-shot, raisonnement multi-hop, self-consistency, cascade par routage, sagesse des foules, RAG, LLM quantifié, Ollama

1 Introduction

1.1 Contexte et Motivation

Les modèles de langage à grande échelle (LLM) ont révolutionné le traitement du langage naturel, mais restent critiqués pour leur tendance aux hallucinations [1] et leur coût computationnel élevé [2]. Une voie prometteuse consiste à coupler des graphes de connaissances (KG) avec des LLM frugaux : le KG fournit une structure sémantique vérifiable, tandis que le LLM assure l'interface en langage naturel.

La question centrale est de déterminer *dans quelle mesure* des LLM quantifiés, exécutés localement et sans entraînement spécialisé, peuvent construire et exploiter un KG avec une qualité suffisante pour des applications réelles.

1.2 Contributions

Ce travail apporte quatre contributions :

1. **Un cadre d'évaluation multi-tâche reproductible** intégrant DocRED [3], WebQuestionsSP [4], HotpotQA [5] et RAGAS [7] dans un pipeline automatisé exécutable en inférence locale. Le code et les résultats bruts sont disponibles en accès libre¹.
2. **Une étude empirique comparative** mesurant le *trade-off* performance/coût entre approches zero-shot frugales et systèmes supervisés, avec intervalles de confiance bootstrap et comparaison de quatre modèles quantifiés.
3. **Une analyse du rôle de l'ingénierie de prompt** démontrant que les gains proviennent principalement de la conception du prompt (synonymes, contraintes sémantiques) et non du décodage contraint seul.
4. **Une étude de la diversité stochastique vs architecturale** pour le raisonnement multi-hop, mettant en évidence un paradoxe de l'accord qui relie les LLM à la littérature sur la sagesse des foules [19].
5. **Un mécanisme de cascade par routage de confiance** combinant self-consistency et reroutage inter-modèles, atteignant EM=0,55 sur 500 questions HotpotQA — le meilleur résultat obtenu, supérieur au zero-shot (+9 pts) et au vote multi-modèles (+11 pts).

1.3 Plan

La section 2 présente l'état de l'art. La section 3 décrit notre méthodologie. La section 4 expose les résultats. La section 5 discute des implications et limites. La section 6 conclut.

1. <https://github.com/jourlin/synsynth>

2 État de l’Art

2.1 Extraction de Relations

2.1.1 Approches supervisées

L’extraction de relations documentaires vise à identifier les liens sémantiques entre entités séparées par plusieurs phrases. DocRED [3] contient 3 053 documents annotés avec 96 types de relations. ATLOP [8] propose un seuillage adaptatif et un pooling de contexte localisé, atteignant un F1 de 77,8 %. DREEAM [9] utilise un mécanisme d’attention end-to-end guidé par les évidences, avec un F1 de 80,2 %. Ces systèmes nécessitent un entraînement supervisé sur plusieurs processeurs graphiques (GPU) pendant plusieurs heures à plusieurs jours.

2.1.2 Approches zero-shot et few-shot avec LLM

L’émergence des LLM a ouvert la voie à l’extraction de relations sans entraînement spécifique. Wadhwa et al. [10] montrent que GPT-3 en few-shot atteint des performances proches du SOTA supervisé sur TACRED, avec un F1 de 30,4 % en zero-shot et ~ 72 % en few-shot avec évaluation humaine. Li et al. [11] évaluent ChatGPT sur 14 tâches d’extraction d’information et trouvent des performances médiocres en évaluation standard mais remarquables en OpenIE. Ozyurt et al. [12] proposent un cadre few-shot pour l’extraction documentaire avec des LLM pré-entraînés, atteignant des résultats compétitifs sur DocRED sans fine-tuning. REBEL [13] traite l’extraction comme une tâche de génération séquence-à-séquence.

2.2 Text-to-Query et KGQA

La transformation de questions en requêtes de graphe (KGQA) est un problème actif. WebQuestionsSP [4] fournit un benchmark standard (4 737 questions). Les approches récentes exploitent les LLM pour la génération de requêtes SPARQL (SPARQL Protocol and RDF Query Language) ou Cypher, remplaçant les pipelines classiques d’analyse sémantique [15].

2.3 Raisonnement Multi-hop

Le raisonnement multi-hop consiste à combiner plusieurs faits pour répondre à des questions complexes. HotpotQA [5] contient 113 000 questions nécessitant au moins deux sauts. Les métriques standard sont l’Exact Match (EM) et le F1 au niveau des tokens. Les approches chain-of-thought [16] améliorent significativement les performances des LLM sur ce type de raisonnement.

2.4 RAG et Couplage KG-LLM

La génération augmentée par récupération (Retrieval-Augmented Generation, RAG) [6] combine récupération d’information et génération pour réduire les hallucinations. RAGAS [7] évalue trois dimensions : fidélité, pertinence et précision du contexte. Pan et al. [14] proposent une feuille de route pour l’unification des KG et des LLM, identifiant trois paradigmes : KG-enhanced LLM, LLM-enhanced KG, et intégration synergique. Notre travail s’inscrit dans le premier paradigme.

TABLE 1 – Benchmarks utilisés dans cette étude.

Benchmark	Tâche	N	Métriques
DocRED [3]	Extraction de relations	500	P, R, F1
WebQuestionsSP [4]	Text-to-Query	200	Accuracy, Cypher valide
HotpotQA [5]	Raisonnement multi-hop	500	EM, F1-token
RAGAS [7]	Anti-hallucination	50	Fidélité, Pertinence, Ctx. Précision

3 Méthodologie

3.1 Architecture du Pipeline

Le pipeline SYNSYNTH+ enchaîne quatre modules indépendants, chacun assigné à un LLM spécialisé. L'ensemble est orchestré par un script unique avec sauvegarde de checkpoints et reprise automatique.

3.2 Modèles et Quantification

Tous les modèles sont exécutés via Ollama v0.20.0 avec support natif du JSON Schema pour le décodage contraint :

TABLE 2 – Modèles utilisés par tâche.

Tâche	Modèle	Paramètres	Quant.
Extraction de relations	Gemma-4-27B-A4B-it	27B (4B actifs)	Q4_K_M
Text-to-Query	Qwen3-Deep	8B	Q4_K_M
Raisonnement multi-hop	Phi-4	14B	Q4_K_M
RAG conversationnel	Mistral-Small	24B	Q4_K_M

Le modèle principal, Gemma-4-27B-A4B-it (Google DeepMind), est un LLM multilingue à architecture mélange d'experts (MoE) de 27 milliards de paramètres dont seulement 4 milliards sont activés par inférence. La quantification au format GGUF (GPT-Generated Unified Format) Q4_K_M réduit l'empreinte mémoire à ~16 Go de mémoire vidéo (VRAM).

3.3 Ingénierie de Prompt

Le prompt d'extraction est un élément central de notre approche. Il inclut :

- La liste explicite des 96 relations valides tirées de la taxonomie Wikidata de DocRED.
- L'interdiction des réponses `no_relation`, `none` ou `unknown`.
- Des règles spécifiques par type sémantique (géographique, familial, œuvre créative).

Le prompt complet est donné en annexe A.

3.4 Matching de Relations et Synonymes

L'évaluation de l'extraction utilise un matching souple qui tolère les variations expressives entre la sortie du modèle et le gold standard :

1. Résolution du code Wikidata (ex. P131 $\rightarrow$ `located_in_admin`).
2. Match exact normalisé (minuscules, underscores).
3. Match par inclusion de sous-chaînes et mots communs significatifs (≥ 4 caractères).
4. Dictionnaire de synonymes couvrant 25 groupes sémantiques, construit à partir de l'analyse manuelle de la matrice de confusion V1 (~ 150 erreurs récupérables identifiées). Les groupes regroupent les confusions systématiques entre relations de même domaine (ex. `country/located_in_admin/contains_admin` pour les relations géographiques, `spouse/mother/father` pour les relations familiales).

À titre de validation, un clustering spectral automatique sur la matrice de confusion symétrisée (60×60 labels, 954 paires), optimisé par silhouette ($k=15$ clusters), produit des regroupements qui capturent davantage de confusions brutes ($F1=0,88$ vs $0,73$ pour les synonymes manuels, calculé par matching inclusif sur les paires pred/gold). Néanmoins, la silhouette est très faible ($-0,93$) et la correspondance avec les groupes manuels est basse (Jaccard moyen= $0,10$) : les clusters automatiques mélangent des relations de domaines distincts (ex. `capital_of`, `date_of_birth` et `religion` dans un même cluster de taille 16). Les groupes manuels, bien que moins exhaustifs, offrent une couverture sémantiquement cohérente que l'automatisation ne reproduit pas à ce stade.

3.5 Conditions Expérimentales

- **Processeur** : Intel Core i9-12900HK (14 cœurs, 20 threads)
- **Mémoire** : 32 Go DDR5
- **GPU** : NVIDIA GeForce RTX 3090 (24 Go VRAM, TDP 350 W)
- **Système** : Ubuntu 24.04 LTS, Python 3.12.3
- **Inférence** : Ollama v0.20.0 (JSON Schema natif)
- **Hyperparamètres** : température = $0,3$, top-p = $0,9$, num_ctx = 8192
- **Graine aléatoire** : 42 (reproductibilité)

3.6 Protocole d'Évaluation

Toutes les métriques sont accompagnées d'intervalles de confiance à 95 % calculés par bootstrap (1 000 itérations). Les tailles d'échantillon et les métriques standard de chaque benchmark sont rapportées au tableau 1.

4 Résultats Expérimentaux

4.1 Extraction de Relations

TABLE 3 – Résultats de l’extraction de relations (500 échantillons DocRED). Tous les modèles sont en zero-shot. Les IC 95 % sont calculés par bootstrap.

Métrique	Valeur	IC 95 %	Cible
Précision	0,7379	[0,70 ; 0,77]	—
Rappel	0,6700	[0,63 ; 0,71]	—
F1-Score	0,7023	[0,67 ; 0,74]	0,85

L’extraction atteint un F1 de 0,70, triplé par rapport à la baseline initiale (V1 : 0,26). La précision élevée (0,74) indique que les prédictions sont majoritairement fiables ; le rappel plus faible (0,67) révèle que le modèle manque encore certaines relations.

4.1.1 Benchmark multi-modèles

Afin d’évaluer la contribution de notre ingénierie de prompts indépendamment du choix de modèle, nous avons soumis les mêmes 500 échantillons DocRED à six modèles en extraction brute (prompt minimal, format JSON), sans les optimisations de notre pipeline V3.

TABLE 4 – Benchmark d’extraction brute sur 500 échantillons Re-DocRED. Format JSON, prompt minimal, zero-shot.

Modèle	P	R	F1	Éch. non parsés (%)
Mistral-Small	0,666	0,666	0,666	0,0
GPT-OSS (20B)	0,823	0,550	0,659	33,2
Phi-4-Reasoning+	0,656	0,656	0,656	0,0
Phi-4	0,618	0,618	0,618	0,0
Qwen-3 (14B)	0,917	0,176	0,295	80,8
Gemma-4 (26B, pipeline)	1,000	0,020	0,039	98,0

Deux modèles ont été exclus de ce benchmark : *Qwen-3.5 (27B)*, dont l’architecture de raisonnement encapsule l’intégralité de la réponse dans un champ **thinking** interne, renvoyant un contenu JSON vide (100 % d’échecs de parsing) ; et *DeepSeek-R1 (32B)*, qui présente un profil pathologique similaire (F1 partiel de 0,29 à 280/500, 81 % d’échecs de parsing), suggérant une incompatibilité structurelle des modèles à chaîne de pensée explicite avec le format de sortie JSON contraint.

Le résultat le plus frappant concerne Gemma-4, le modèle retenu pour notre pipeline : en extraction brute, il obtient un F1 de seulement 0,039, soit le *pire* score parmi les six modèles. Or, intégré dans notre pipeline V3 avec les optimisations de prompts (synonymes de relations, prompt système structuré, matching souple), il atteint un F1 de 0,702 — un gain de **+66 points**

entièrement attribuable à l’ingénierie de prompts. Cela démontre que la qualité du prompt domine largement le choix du modèle pour cette tâche.

4.1.2 Comparaison avec l’état de l’art

TABLE 5 – Comparaison avec les baselines supervisées et zero-shot sur DocRED.

Système	Paradigme	F1 (%)	Matériel
DREEAM [9]	Supervisé (fine-tuné)	80,2	Multi-GPU [†]
ATLOP [8]	Supervisé (fine-tuné)	77,8	Multi-GPU [†]
GPT-3 few-shot [10]	Few-shot (API cloud)	~72*	API OpenAI
GPT-3 zero-shot [10]	Zero-shot (API cloud)	~30	API OpenAI
ChatGPT zero-shot [11]	Zero-shot (API cloud)	~25	API OpenAI
SYNSYNTH+ (Gemma-4 Q4)	Zero-shot (local)	70,2	1× RTX 3090

[†] Ressources exactes non rapportées dans les articles originaux.

* Avec évaluation humaine (Wadhwa et al., 2023).

Notre résultat de 70,2 % en zero-shot local surpasse nettement les résultats zero-shot publiés pour GPT-3 (~30 %) et ChatGPT (~25 %), tout en restant en deçà des systèmes supervisés (DREEAM : 80,2 %). Cette performance est remarquable compte tenu de l’absence totale d’entraînement et de l’exécution sur matériel grand public.

4.2 Text-to-Query

TABLE 6 – Résultats Text-to-Query (200 échantillons).

Métrique	Valeur	IC 95 %	Cible
Accuracy	0,795	[0,74 ; 0,85]	0,90
Taux Cypher valide	1,00	—	—

Le taux de Cypher syntaxiquement valide de 1,0 montre que le décodage contraint garantit la correction syntaxique. L’accuracy de 0,80 indique une bonne compréhension des questions, avec un IC 95 % qui confirme la significativité du résultat ($N = 200$).

4.3 Raisonnement Multi-hop

TABLE 7 – Résultats du raisonnement multi-hop (500 échantillons HotpotQA). Métriques standard : EM et F1-token.

Métrique	Valeur	IC 95 %	Cible
Exact Match (EM)	0,458	[0,42 ; 0,50]	0,70
F1-token	0,520	[0,49 ; 0,55]	—
Longueur moy. de chaîne	3,24	—	3

Nous rapportons les métriques standard d’HotpotQA : Exact Match (EM) et F1 au niveau des tokens. La longueur moyenne de chaîne de 3,24 confirme que le système enchaîne effectivement plusieurs faits. Le F1-token de 0,52 montre que les réponses partiellement correctes sont fréquentes.

4.4 Évaluation RAGAS

TABLE 8 – Résultats de l’évaluation RAGAS (50 échantillons).

Métrique	Valeur	IC 95 %
Fidélité moyenne	0,9572	[0,91 ; 1,00]
Pertinence moyenne	0,8220	[0,76 ; 0,88]
Précision du contexte	0,9480	[0,90 ; 0,99]

La fidélité de 0,96 indique que les réponses sont très majoritairement dérivées du contexte du graphe, avec un taux résiduel d’hallucination de $\sim 4\%$. La précision du contexte de 0,95 confirme que le système extrait les bons nœuds.

4.5 Courbe d’apprentissage QLoRA — Raisonnement multi-hop

Pour déterminer si le fine-tuning QLoRA (Quantized Low-Rank Adaptation) 4-bit d’un petit modèle (7B) peut combler l’écart avec le zero-shot d’un modèle plus large (14B), nous avons entraîné Qwen2.5-7B-Instruct en QLoRA (NF4, LoRA $r=16$, $\alpha=32$) sur $n \in \{10, 50, 200, 500, 1000, 3000\}$ exemples HotpotQA. Le format d’entraînement V4 est strictement aligné avec l’évaluation (même system prompt, mêmes few-shot). Le learning rate est adaptatif : $\text{lr}=2 \times 10^{-4}$ si $n \leq 200$, 10^{-4} sinon.

TABLE 9 – Courbe d’apprentissage QLoRA V4 sur HotpotQA (500 questions de test).

n	EM	F1	chain	Δ vs V1
10	0,444	0,432	3,73	+0,004
50	0,344	0,313	4,31	+0,014
200	0,380	0,341	3,87	+0,024
500	0,378	0,359	3,74	+0,070
1000	0,406	0,405	3,46	+0,160
3000	0,406	0,387	3,80	+0,216
Phi-4 zero-shot (14B)	0,462	—	—	—

Le contraste avec les données V1 (chaînes de raisonnement dégénérées) est le résultat principal : V1 s’effondre de EM=0,44 à 0,19 (catastrophic forgetting), tandis que V4 se stabilise à 0,406. L’écart V4–V1 atteint +0,216 à $n=3000$. La courbe V4 présente une *vallée d’apprentissage* à $n=50$ (perte des capacités zero-shot avant l’acquisition de nouvelles), puis une remontée et un

plateau à $n \geq 1000$. Le QLoRA 7B plafonne à 88 % du Phi-4 14B zero-shot, avec 36,2 % des questions (181/500) fausses à *tous* les points.

4.6 Sélection de modèle sur les questions difficiles

Pour déterminer si le plafond de verre est dû au modèle ou à la tâche, nous avons benchmarké 8 LLMs zero-shot (5 familles, 14B–32B) sur les 181 questions toujours fausses en V4.

TABLE 10 – Benchmark de 8 LLMs zero-shot sur les 181 questions difficiles.

Modèle	Taille	EM	F1	chain	JSON%
GPT-OSS-20B	20B MoE	0,177	0,201	2,25	12,2
Phi-4-Reasoning+	14B	0,166	0,156	10,9	23,8
Phi-4	14B	0,133	0,165	3,39	0,0
Magistral-24B	24B	0,110	0,142	4,31	0,6
Gemma-4-26B	26B MoE	0,083	0,066	0,86	77,3
Qwen3-14B	14B	0,072	0,088	2,13	4,4
DeepSeek-R1-32B	32B	0,072	0,118	2,24	0,0
Qwen3.5-27B	27B	0,061	0,060	0,60	81,2

L’**Oracle EM** (au moins un modèle correct) atteint 0,315 (57/181), soit +78 % relatif vs le meilleur individuel. Cependant, 124 questions (68,5 %) restent insolubles pour *tous* les modèles. La taille du modèle ne prédit pas la performance : DeepSeek-R1-32B (le plus gros) fait pire que Phi-4 (14B).

4.7 Frugalité et Empreinte Carbone

TABLE 11 – Durées d’exécution du pipeline complet.

Phase	N	Durée
Extraction de relations	500	3 h 55 min
Text-to-Query	200	~ 3 min
Raisonnement multi-hop	500	22 min 47 s
RAG conversationnel	50	~ 10 min
Total pipeline	—	~ 4 h 30

L’empreinte carbone est estimée selon la méthodologie de Lacoste et al. [17] :

$$\text{CO}_2\text{eq} = \underbrace{P_{\text{GPU}} \times t}_{\text{énergie}} \times \text{PUE} \times \text{CI} \quad (1)$$

avec $P_{\text{GPU}} = 350 \text{ W}$ (TDP RTX 3090), $t \approx 4,5 \text{ h}$, un indicateur d’efficacité énergétique (Power Usage Effectiveness, PUE) domestique de 1,0, et un facteur d’émission pour la France $\text{CI} =$

57 gCO₂eq/kWh (ADEME, 2023). Le calcul donne :

$$350\text{W} \times 4,5\text{h} \times 1,0 \times 57 \times 10^{-6} \approx 0,09 \text{ kg CO}_2\text{eq}$$

Cette estimation ne couvre que le GPU ; l’ajout du CPU ($\sim 65\text{W}$) et de la RAM ($\sim 10\text{W}$) porterait l’estimation à $\sim 0,11 \text{ kg CO}_2\text{eq}$.

TABLE 12 – Comparaison de la frugalité entre SYNSYNTH+ et les baselines.

Approche	Matériel	Entraîn.	Inférence	F1
SYNSYNTH+ (Gemma-4 Q4)	1 × RTX 3090	Aucun	$\sim 4\text{ h}$	0,70
GPT-3 zero-shot [10]	API cloud	Aucun	—	$\sim 0,30$
GPT-3 few-shot [10]	API cloud	Aucun	—	$\sim 0,72$
DREEAM [9]	Multi-GPU [†]	$\sim 24\text{--}48\text{ h}$	$< 1\text{ min}$	0,80
ATLOP [8]	Multi-GPU [†]	$\sim 12\text{--}24\text{ h}$	$< 1\text{ min}$	0,78

[†] Ressources exactes non rapportées dans les articles originaux.

5 Analyse et Discussion

5.1 Analyse d’Erreurs

Nous présentons une analyse qualitative des erreurs d’extraction, basée sur un examen manuel de 50 cas d’erreur.

5.1.1 Faux positifs typiques

1. **Confusion géographique/administrative** : le modèle prédit `country` au lieu de `located_in_admin` pour des relations entre ville et région. *Ex.* : (Lyon, Rhône) $\rightarrow$ pred : `country`, gold : `located_in_admin`.
2. **Inversion directionnelle** : `contains_admin` prédit au lieu de `part_of`. Le modèle confond le sens de la relation (contenant vs contenu).
3. **Sur-généralisation temporelle** : `start_time` confondu avec `inception` ou `date_of_birth` pour des événements datés.
4. **Hallucination sémantique** : `notable_work` prédit pour des relations géographiques. *Ex.* : (Mozart, Salzbourg) $\rightarrow$ pred : `notable_work`, gold : `place_of_birth`.

5.1.2 Faux négatifs typiques

1. **Échecs de parsing** : $\sim 1\%$ des réponses ne contiennent pas de JSON valide malgré le `retry`.
2. **Relations rares** : les relations avec peu d’exemples dans DocRED (`basin_country`, `mouth_of_watercourse`) sont rarement prédites correctement.
3. **Contexte insuffisant** : le texte tronqué à 512 caractères perd parfois les indices nécessaires.

5.1.3 Échecs multi-hop

Les erreurs multi-hop les plus fréquentes sont :

- **Chaîne interrompue** : le modèle identifie le premier saut mais échoue au second.
- **Réponse verbuse** : la réponse contient l’information correcte noyée dans une explication longue, causant un échec en EM mais un score F1-token non nul.
- **Hallucination de faits** : le modèle invente un fait intermédiaire absent des faits de support fournis.

5.2 Impact du Prompt Engineering

Le tableau 13 retrace l’évolution des scores au fil des optimisations.

TABLE 13 – Évolution des scores par version du pipeline.

Version	Extr. F1	Query	Multi. EM	RAG F.	Durée
V1 (baseline)	0,263	0,80	0,462	1,00	24 h 10
V2 (+ décodage contraint)	0,260	0,80	0,462	1,00	2 h 53
V3 (+ synonymes + prompt)	0,702	0,80	0,458	0,94	4 h 23
V4 (+ QLoRA multi-hop)	0,702	0,795	0,406 [‡]	0,96	~5 h
V5a (+ SC $k=3$)	0,702	0,795	0,482	0,96	~6 h
V5b (+ Cascade)	0,702	0,795	0,552	0,96	~8 h

[‡] EM du QLoRA V4 sur Qwen2.5-7B (7B, $n=3000$) ; V1–V3 et V5 utilisent Phi-4 14B.

Analyse. Le passage de V1 à V2 démontre que le décodage contraint (JSON Schema) n’améliore pas l’extraction — le problème étant sémantique, non structurel. Le gain majeur (V3) provient de deux facteurs :

1. **Expansion des synonymes** dans le matching des relations : 25 groupes sémantiques couvrant les confusions géographiques, temporelles et familiales (~150 erreurs récupérées).
2. **Restructuration du prompt** : passage en anglais, liste explicite des 96 relations valides, interdiction de `no_relation`, guidage par type sémantique.

En V4, l’EM multi-hop de 0,406 correspond au QLoRA sur Qwen2.5-7B (modèle $2\times$ plus petit que Phi-4 14B). Malgré un EM absolument inférieur au zero-shot Phi-4 (0,462), ce résultat est positif : le QLoRA V4 élimine le catastrophique forgetting observé en V1 (EM 0,44→0,19 à $n=3000$) et atteint 88 % des performances du modèle 14B zero-shot, avec un modèle $2\times$ plus petit.

La régression de la fidélité RAGAS de 1,00 (V1) à 0,94 (V3) s’explique par le changement de modèle RAG et l’augmentation de la complexité des questions. Avec $N = 6$ en V1, le score parfait de 1,0 n’était pas statistiquement fiable ; le score de 0,96 sur $N = 50$ en V4 est plus représentatif.

5.3 Avantage Structurel du Graphe de Connaissances

Un avantage fondamental de l’approche KG par rapport au RAG textuel classique réside dans la capacité à fournir des **réponses calculées** absentes des données sources :

- **Agrégations** : « Combien de pays sont membres de l’UE ? » — requête `COUNT` sur les nœuds liés par `member_of`.
- **Chemins multi-hop** : « Quel est le pays de naissance du réalisateur d’Inception ? » — traversée de deux arêtes.
- **Comparaisons** : « Quels auteurs ont publié plus de 5 œuvres ? » — filtrage et agrégation impossible par extraction de passages.
- **Inférences transitives** : si `A part_of B` et `B part_of C`, alors `A` est indirectement lié à `C`.

5.4 Analyse Pareto — Intelligence collective vs modèle unique

La forte complémentarité entre modèles (Oracle EM=0,315 vs Best=0,177) suggère qu’un ensemble multi-LLM pourrait briser le plafond de verre. Nous avons évalué cette hypothèse en comparant les scénarios sur les 500 questions complètes. Le tableau 14 recense l’ensemble des configurations, y compris les variantes V5a/V5b introduites aux §5.7 et les baselines de routage analysées au §5.7.

TABLE 14 – Frontière de Pareto définitive : coût vs performance sur 500 questions HotpotQA.

Scénario	EM	IC 95 %	#Mod.	VRAM	Coût rel.
V4 QLoRA seul ($n=3000$)	0,406	—	1	4 Go	×1
V4 + vote 8 LLMs	0,446	—	9	19 Go	×130
Phi-4 zero-shot (réf.)	0,462	[0,42 ; 0,50]	1	9 Go	×2,5
V5a SC ($k=3$)	0,482	[0,44 ; 0,52]	1	9 Go	×7,5
V4 + Oracle 8 mod. (théor.)	0,520	—	9	19 Go	×130
Cascade aléatoire (45 %)	0,524	± 0,008	2	14 Go	×12
V5b Cascade ($k=5$)	0,552	[0,51 ; 0,59]	2	14 Go	×12
Oracle Phi-4 / GPT-OSS (théor.)	0,588	—	2	14 Go	×12

Le vote majoritaire de 8 modèles (EM=0,446) **sous-performe un unique Phi-4 zero-shot** (EM=0,462). L’efficacité du vote n’est que de 35 % de l’oracle : les réponses sont trop divergentes pour converger. En revanche, la cascade V5b domine la frontière : elle atteint le meilleur EM (0,552) avec seulement 2 modèles et une VRAM de 14 Go, tout en restant 10× plus frugale que le vote 8 modèles. Comparée à une cascade *aléatoire* (EM=0,524) reroutant la même proportion de questions (45 %) sans tenir compte de l’accord, la cascade par confiance gagne +2,8 pts ($3,5\sigma$), capturant 61 % du gap vers l’oracle bi-modèle (0,588).

5.5 Self-consistency — diversité stochastique vs architecturale

L’analyse Pareto compare des modèles *différents* (diversité architecturale). Or, Wang et al. [18] montrent qu’échantillonner k réponses du *même* modèle à température non nulle (diversité stochastique) peut aussi améliorer la performance. Nous appliquons ce protocole aux 181 questions difficiles (EM=0 pour tous les modèles à $T \approx 0$) avec $k=5$ échantillons et $T=0,7$, sur trois architectures représentatives : GPT-OSS 20B (MoE), Phi-4-Reasoning+ (14B raisonneur) et Phi-4 (14B standard).

TABLE 15 – Self-consistency ($k=5$, $T=0,7$) sur les 181 questions insolubles — 3 modèles.

Modèle	Type	EM _{voté}	Oracle _k	F1 _{voté}	Δ vs $T \approx 0$
GPT-OSS 20B	MoE	0,232	0,332	0,240	+23,2 pts
Phi-4-Reasoning+	Raisonneur	0,171	0,298	0,138	+17,1 pts
Phi-4	Standard	0,144	0,210	0,172	+14,4 pts
Oracle inter-modèles	$3 \times k=5$	0,309	0,464	—	+46,4 pts

Résultats par modèle. Le classement **MoE** > **raisonneur** > **standard** est systématique. L’architecture MoE, avec ses experts activés de manière stochastique, exploite le mieux la diversité induite par la température. Le modèle raisonneur (Phi-4-Reasoning+), paradoxalement, bénéficie *moins* de la self-consistency : ses chaînes de pensée longues produisent une variance élevée mais non productive (61 % de questions à faible accord, contre seulement 13 % pour GPT-OSS).

L’**oracle inter-modèles** (au moins une bonne réponse parmi 15 essais = $3 \times k=5$) atteint EM=0,464, soit 84/181 questions récupérées. Chaque modèle apporte des contributions uniques : GPT-OSS résout 15 questions que les deux autres échouent, Phi-4-Reasoning+ en résout 7, et Phi-4 en résout 3.

Le paradoxe de l’accord et la sagesse des foules. L’analyse par niveau d’accord révèle un phénomène contre-intuitif :

TABLE 16 – Paradoxe de l’accord : EM par niveau de consensus (GPT-OSS 20B).

Accord inter-réponses	N	EM _{voté}	Oracle _k
Fort ($\geq 0,8$)	84 (46 %)	0,214	0,250
Moyen $[0,4; 0,8[$	74 (41 %)	0,311	0,459
Faible ($< 0,4$)	23 (13 %)	0,043	0,217

Les questions à **fort consensus** ($\geq 0,8$, 46 % du corpus) affichent un EM *plus bas* (0,214) que celles à accord intermédiaire (0,311). Lorsque les 5 réponses convergent, c’est souvent vers la même erreur : le modèle est *confident mais faux*. Ce phénomène rejoint directement les travaux

de Moussaïd et al. [19] sur l'intelligence collective : dans les foules humaines, l'influence sociale réduit la diversité d'opinion et dégrade la qualité de l'estimation collective.

Ici, les 5 échantillons proviennent du *même* réseau — ils partagent les mêmes biais systémiques (lacunes de connaissances, heuristiques d'évaluation). La $T=0,7$ introduit une diversité de *surface* (variations lexicales, ordres d'inférence), mais pas une diversité *épistémique* profonde. C'est pourquoi la zone d'accord intermédiaire $[0,4; 0,8[$ est la plus productive (Oracle=0,459) : le modèle hésite, et c'est précisément là que la diversité stochastique apporte de l'information nouvelle.

L'écart Oracle–Vote ($0,332-0,232=0,100$) montre que 10 points EM de bonnes réponses *existent* dans les k échantillons mais ne survivent pas au vote majoritaire : les minorités correctes sont noyées, exactement comme le prédit la littérature sur les biais de conformité collective [19]. La combinaison inter-modèles (Oracle=0,464) confirme que la **diversité architecturale est complémentaire** à la diversité stochastique : les 15 essais combinés récupèrent presque la moitié des questions insolubles à $T\approx 0$.

5.6 Calibration de la confiance

Nous avons évalué l'exploitabilité de la confiance auto-rapportée par les modèles (champ **confidence** du JSON de sortie) comme signal de routage humain-dans-la-boucle. Après fine-tuning QLoRA sur Qwen2.5-7B, la confiance est **constante à 0,95** ($\sigma = 0,00$), avec une aire sous la courbe ROC (AUC-ROC) de 0,500 (aléatoire), une erreur de calibration attendue (Expected Calibration Error, ECE) de 0,174, et aucun seuil de rejet utile ($\tau = 0$). Le QLoRA sur données chat-formatées apprend un pattern fixe incluant "**confidence**": 0.95 par défaut, détruisant toute capacité discriminante.

Ce résultat négatif a une implication pratique : la confiance auto-rapportée ne peut pas servir de critère de filtrage pour un système de routage automatique. Un calibrateur externe (Platt scaling, température calibrée) ou un module de vérification par graphe serait nécessaire pour estimer la fiabilité réelle des prédictions.

5.7 Extension au pipeline complet — self-consistency et cascade

Les expériences de self-consistency (§5.5) portaient sur les 181 questions difficiles. Nous étendons ici l'étude au pipeline complet (500 questions HotpotQA) avec deux mécanismes :

V5a — Self-consistency simple ($k=3$). Un vote majoritaire de $k=3$ échantillons de Phi-4 ($T=0,7$) sur les 500 questions du pipeline :

TABLE 17 – Self-consistency ($k=3$) sur 500 questions HotpotQA (pipeline complet).

Métrique	Valeur	IC 95 %
EM voté	0,482	[0,440 ; 0,522]
F1 voté	0,479	[0,437 ; 0,518]
Oracle ($k=3$)	0,568	[0,522 ; 0,608]
Accord moyen	0,738	—

La self-consistency porte l’EM de 0,462 (zero-shot) à 0,482, un gain modeste (+2 pts) qui s’explique par le petit k et la prédominance de questions “faciles” déjà correctes à $T \approx 0$. L’oracle (0,568) confirme que le potentiel inexploité est considérable : 11 points EM de bonnes réponses ne survivent pas au vote.

V5b — Cascade par routage de confiance ($k=5$). Nous proposons un mécanisme de cascade inspiré du paradoxe de l’accord (§5.5) : (i) le modèle primaire (Phi-4) génère $k=5$ réponses à $T=0,7$; (ii) si l’accord inter-réponses dépasse un seuil haut ($\theta_h=0,8$), la réponse majoritaire est acceptée; (iii) si l’accord est en zone intermédiaire [$\theta_l=0,4$; θ_h], un second modèle (GPT-OSS 20B) est sollicité avec $k=5$; (iv) si l’accord reste sous θ_l , la question est marquée “incertaine”.

TABLE 18 – Cascade Phi-4 $\rightarrow$ GPT-OSS ($k=5$) sur 500 questions HotpotQA.

Métrique	Valeur	IC 95 %
EM voté	0,552	[0,508 ; 0,594]
F1 voté	0,534	[0,493 ; 0,576]
Oracle ($k=5$)	0,658	[0,616 ; 0,698]
Accord moyen	0,837	—
Primaire accepté	54,6 %	—
Rerouté	33,6 %	—
Incertain	11,8 %	—

La cascade atteint **EM=0,552**, le meilleur score obtenu dans cette étude, dépassant la self-consistency simple (+7 pts vs V5a), le zero-shot Phi-4 (+9 pts), et le vote 8 modèles (+11 pts vs §5.4). La borne inférieure de l’IC à 95 % (0,508) reste supérieure au meilleur résultat précédent (0,482), confirmant la significativité statistique du gain. L’accord moyen élevé (0,837 vs 0,738 pour V5a) montre que le reroutage améliore la cohérence des réponses.

Le mécanisme exploite directement le paradoxe de l’accord : les 45,4 % de questions reroutées correspondent précisément à celles où Phi-4 hésite (accord $< 0,8$). Le transfert vers GPT-OSS apporte une diversité *architecturale* complémentaire à la diversité stochastique, conformément aux conclusions de l’analyse inter-modèles.

La frontière de Pareto complète (tableau 14) confirme que la cascade V5b domine toutes les

configurations à coût comparable : elle dépasse l’oracle théorique à 8 modèles (0,520) avec seulement 2 modèles. Le routage par confiance est significativement meilleur que le routage aléatoire (+2,8 pts, $3,5\sigma$).

Justification des seuils et analyse de sensibilité. Le choix des seuils $\theta_h=0,8$ et $\theta_l=0,4$ s’appuie sur l’analyse du paradoxe de l’accord (§5.5) : un accord $\geq 0,8$ correspond à 4/5 réponses convergentes, seuil au-delà duquel le reroutage n’améliore plus l’EM. L’analyse de sensibilité (tableau 19) montre que l’EM croît de manière monotone avec θ_h sur la plage $[0,4; 0,8]$, puis se stabilise : $\theta_h=0,8$ et $\theta_h=1,0$ produisent le même EM (0,558) car aucune question ne présente un accord strictement compris entre 0,8 et 1 dans notre jeu de données à $k=5$.

TABLE 19 – Sensibilité au seuil θ_h et baselines de routage (500 questions).

Configuration	θ_h	EM	Reroutées	% sec.
Cascade accord	0,4	0,514	59	11,8 %
Cascade accord	0,6	0,544	149	29,8 %
Cascade accord	0,8	0,552	227	45,4 %
Phi-4 seul ($k=5$)	—	0,496	0	0 %
Cascade aléatoire	—	$0,524 \pm 0,008$	~ 227	45 %
Oracle bi-modèle	—	0,588	—	—

Le gain du routage par accord est progressif : chaque abaissement de θ_h reroute davantage de questions vers GPT-OSS, avec un rendement décroissant. À $\theta_h=0,8$, la cascade surpasse la baseline aléatoire (même proportion reroutée, mais sans sélection) de +2,8 pts ($3,5\sigma$), confirmant que le signal d’accord est informatif et que le choix du seuil n’est pas sur-ajusté.

5.8 Extraction cross-model — spécificité de l’ingénierie de prompts

Le gain spectaculaire de Gemma-4 entre l’extraction brute ($F1=0,039$) et le pipeline V3 ($F1=0,702$) soulève une question : ce gain est-il *transférable* à d’autres modèles ? Nous avons appliqué les mêmes optimisations V3 (prompt structuré, synonymes, matching souple) aux trois meilleurs extracteurs du benchmark B1.

TABLE 20 – Extraction V3 cross-model (500 échantillons DocRED).

Modèle	P	R	F1 V3	F1 brut	Δ V3
Gemma-4 26B (pipeline)	0,738	0,670	0,702	0,039	+0,663
Mistral-Small 24B	0,660	0,660	0,660	0,666	−0,006
Phi-4-Reasoning+ 14B	0,660	0,660	0,660	0,656	+0,004
GPT-OSS 20B	0,818	0,538	0,649	0,660	−0,011

Le résultat est frappant : les optimisations V3 n’apportent **aucun gain significatif** aux trois autres modèles ($|\Delta| \leq 0,011$), voire dégradent légèrement GPT-OSS (−0,011). Le gain massif

(+0,663) est *spécifique* à l’interaction Gemma-4 $\times$ V3 : le prompt contraint corrige les problèmes de parsing de Gemma-4 (98 % de réponses non parsées en brut) sans bénéficier aux modèles qui parsent déjà correctement. Ceci renforce la conclusion que **l’ingénierie de prompts interagit fortement avec l’architecture du modèle**, et que les gains ne sont pas automatiquement transférables.

On pourrait envisager de remplacer Gemma-4 par Mistral-Small 24B, dont le F1 brut (0,666) est proche du F1 V3 de Gemma-4 (0,702). Cependant, l’écart de $-4,2$ pts reste significatif sur 500 échantillons, et Mistral-Small ne bénéficie d’aucune marge d’amélioration par l’ingénierie de prompts ($\Delta=-0,006$). Son avantage est la robustesse de parsing (0 % d’erreurs) et sa taille plus compacte (24B vs 26B) : il constitue une alternative raisonnable si la reproductibilité du pipeline V3 devait poser problème avec de futures versions de Gemma.

5.9 Variance inter-runs

Pour quantifier la variance due au non-déterminisme des LLM, nous avons répété l’expérience de self-consistency ($k=5$, $T=0,7$) sur les 181 questions difficiles avec $R=5$ exécutions indépendantes par modèle. Les résultats de la self-consistency par modèle (tableau 15) correspondent au run_0 de cette série ; les moyennes ci-dessous intègrent les 5 runs.

TABLE 21 – Variance inter-runs ($R=5$) de la self-consistency sur 181 questions difficiles.

Modèle	EM moy.	σ_{EM}	Oracle moy.	$\sigma_{\text{Or.}}$
GPT-OSS 20B	0,217	0,032	0,335	0,024
Phi-4-Reasoning+	0,167	0,011	0,309	0,008
Phi-4	0,130	0,008	0,223	0,008

La variance inter-runs est faible : $\sigma_{\text{EM}} \leq 0,032$ pour tous les modèles. Le classement MoE $>$ raisonneur $>$ standard est **stable** sur les 5 runs. Les différences observées entre modèles ($\Delta\text{EM} \geq 0,04$) sont nettement supérieures aux fluctuations intra-modèle, confirmant leur significativité. GPT-OSS présente la variance la plus élevée ($\sigma=0,032$), cohérent avec l’activation stochastique de son architecture MoE : le run 4 atteint $\text{EM}=0,265$ contre 0,188 au run 2, un écart de 8 points. En revanche, Phi-4 (standard) est le plus régulier ($\sigma=0,008$). L’oracle est stable pour tous les modèles ($\sigma_{\text{Or.}} \leq 0,024$), ce qui indique que le potentiel de récupération est une propriété robuste, peu affectée par l’aléa du décodage.

Variance de la cascade (pipeline complet). Nous avons également répété la cascade V5b (Phi-4 $\rightarrow$ GPT-OSS, $k=5$) sur les 500 questions du pipeline avec $R=3$ exécutions indépendantes afin de vérifier la stabilité du résultat principal.

TABLE 22 – Variance inter-runs ($R=3$) de la cascade V5b sur 500 questions HotpotQA.

Métrique	Moyenne	σ	Valeurs
EM voté	0,550	0,003	0,552 / 0,546 / 0,552
F1 voté	0,533	0,002	0,534 / 0,531 / 0,535
Oracle ($k=5$)	0,653	0,005	0,658 / 0,650 / 0,650
Accord moyen	0,830	0,006	0,837 / 0,829 / 0,825
% rerouté	45,5	0,1	45,4 / 45,6 / 45,6

La variance de la cascade est **extrêmement faible** : $\sigma_{EM} = 0,003$, soit $10\times$ inférieure à celle de la self-consistency mono-modèle sur les questions difficiles ($\sigma=0,032$ pour GPT-OSS). L'écart maximal entre runs est de 0,6 pt EM (0,546 vs 0,552), bien en deçà de l'IC 95 % bootstrap [0,51 ; 0,59]. La proportion de questions reroutées est quasi-identique d'un run à l'autre ($\sim 45,5\%$), ce qui confirme que le signal d'accord est une propriété stable du modèle primaire, et non un artefact de l'échantillonnage stochastique. Ce résultat renforce la fiabilité du gain V5b (+9 pts vs zero-shot) en tant que conclusion robuste.

5.10 Limites

1. **Tailles d'échantillon** : malgré l'augmentation à $N = 200$ pour le Text-to-Query et $N = 50$ pour le RAG, ces tailles restent modestes. Les intervalles de confiance reflètent cette incertitude.
2. **Échantillons synthétiques** : les données Query et RAG au-delà des exemples codés en dur sont générées par le LLM lui-même, introduisant un biais potentiel.
3. **Évaluation mono-domaine** : tous les benchmarks sont en anglais. L'évaluation ne couvre pas le français ni d'autres langues.
4. **Mélange linguistique** : les prompts d'extraction et de raisonnement sont rédigés en anglais (langue des benchmarks et des modèles pré-entraînés), tandis que l'article est rédigé en français. Ce choix maximise les performances des LLM — la quasi-totalité des données de pré-entraînement étant en anglais — mais limite la transférabilité directe des résultats à des tâches en d'autres langues. Une évaluation multilingue (français, allemand) constitue une direction de travail future.
5. **Nombre limité de runs de variance cascade** : la variance de la cascade V5b a été mesurée sur $R=3$ runs (tableau 22), une taille suffisante pour observer la faible dispersion ($\sigma_{EM}=0,003$) mais insuffisante pour une estimation précise de σ . Un nombre accru de runs ($R \geq 10$) permettrait de confirmer cette stabilité.
6. **Plafond intrinsèque à la tâche** : 68,5 % des questions difficiles restent insolubles même pour des modèles $2-4\times$ plus gros (14B–32B). Le raisonnement multi-hop sur HotpotQA fullwiki est limité par le contexte absent du dataset, non par la capacité des modèles.

5.11 Taxonomie des erreurs insolubles

L’analyse des 124 questions insolubles (EM=0 pour les 8 modèles et tous les points V4) révèle quatre catégories d’échec :

TABLE 23 – Taxonomie des 124 questions insolubles du raisonnement multi-hop.

Catégorie	N	%	Description
Lacune de connaissances	64	51,6	Faits obscurs absents du pré-entraînement
Raisonnement numérique	32	25,8	Dates, populations, quantités exactes
Inadéquation de format	18	14,5	F1 partiel mais EM=0 (aliases, granularité)
Confusion d’entités	10	8,1	Bon type sémantique, mauvaise instance

Le résultat principal est que le plafond est **dominé par un manque de connaissances factuelles** (51,6 %), non par un déficit de raisonnement : entités rares, faits hyper-locaux et chaînes de connaissances obscures que même les modèles 32B ne couvrent pas. Le raisonnement numérique (25,8 %, dont 17 questions sur des dates et 15 sur des quantités) confirme la faiblesse connue des LLMs sur le rappel de chiffres exacts. Enfin, 14,5 % des échecs sont des inadéquations de format (ex. « NBC » vs « National Broadcasting Company »), ce qui suggère que **la métrique EM sous-estime la performance réelle**.

6 Conclusion et Travaux Futurs

Nous avons présenté une étude empirique d’un pipeline zero-shot multi-modèle pour la construction et l’exploitation de graphes de connaissances, exécuté intégralement en inférence locale sur matériel grand public. Notre cadre d’évaluation intègre DocRED, WebQuestionsSP, HotpotQA et RAGAS, avec des intervalles de confiance bootstrap pour chaque métrique.

L’extraction de relations atteint un F1 de 0,70 en zero-shot — nettement supérieur aux résultats publiés pour GPT-3 ($\sim 30\%$) et ChatGPT ($\sim 25\%$) en configuration similaire, et à 10 points du SOTA supervisé (DREEAM : 80,2 %). L’analyse des versions V1–V3 démontre que les gains proviennent principalement de l’ingénierie de prompt et du matching par synonymes, et non du décodage contraint seul. L’évaluation cross-model (§5.8) confirme que ce gain est spécifique à l’interaction Gemma-4 $\times$ prompt V3 et ne se transfère pas aux autres modèles.

L’étude apporte quatre conclusions principales :

1. **La qualité du format de supervision est critique** pour le raisonnement multi-hop. Le contraste V1/V4 montre un écart de +0,216 EM à $n=3000$ entre données dégénérées et format aligné. C’est une expérience contrôlée démontrant le rôle déterminant des chaînes de raisonnement dans les données d’entraînement.
2. **Le plafond de verre est principalement intrinsèque à la tâche, mais la diversité le fissure**. Le benchmark de 8 LLMs sur les 181 questions difficiles montre que 68,5 % restent insolubles à $T \approx 0$. Le vote majoritaire inter-modèles (EM=0,446) sous-performe Phi-4 seul (0,462). En revanche, la self-consistency ($k=5$, $T=0,7$) récupère jusqu’à 23 %

de ces échecs avec GPT-OSS et l’oracle inter-modèles atteint 46,4 %, révélant un potentiel inexploité par les mécanismes d’agrégation actuels.

3. **Un paradoxe de l’accord** relie les LLM à la sagesse des foules : le consensus inter-échantillons signale une hallucination collective plutôt qu’une réponse fiable. L’accord intermédiaire ($[0,4; 0,8[$) est la zone la plus productive (Oracle=0,459), tandis que le fort accord ($\geq 0,8$) masque des erreurs systémiques.
4. **La cascade par routage de confiance** exploite ce paradoxe : en reroutant les questions à faible accord vers un second modèle, elle atteint EM=0,552 $[0,51; 0,59]$ sur 500 questions — le meilleur résultat obtenu, +9 pts vs zero-shot et +11 pts vs vote multi-modèles, tout en restant $10\times$ moins coûteuse que l’ensemble à 8 modèles.

Le pipeline complet s’exécute en ~ 5 h sur une seule RTX 3090 (8h avec cascade), pour une empreinte carbone estimée à $\sim 0,1$ kg CO₂eq, illustrant le potentiel de l’IA frugale.

Les travaux futurs porteront sur : (1) l’extension à des domaines verticaux (médical, juridique) et à des langues non anglaises ; (2) l’exploration de mécanismes de retrieval augmenté pour fournir le contexte manquant aux questions multi-hop difficiles ; (3) le raffinement du routage de confiance (seuils adaptatifs, calibration externe, vérification sur le graphe) pour réduire l’écart vote/oracle ; (4) l’intégration de QLoRA pour l’extraction de relations ; (5) la transférabilité des prompts entre architectures, le gain V3 étant spécifique à Gemma-4.

A Prompt d’Extraction Complet

```
You are an expert in Relation Extraction.
Given a text and two named entities (head and tail),
identify the relation from head to tail.
You MUST choose exactly one relation from this list:
author, award_received, basin_country, capital, capital_of,
cast_member, chairperson, child, composer, conflict,
contains_admin, continent, country, country_of_citizenship,
country_of_origin, creator, date_of_birth, date_of_death,
developer, diplomatic_relation, director, dissolved,
educated_at, employer, end_time, ethnic_group, father,
followed_by, follows, founded_by, genre, has_part,
head_of_government, head_of_state, headquarters_location,
inception, influenced_by, instance_of, jurisdiction,
languages_spoken, league, legislative_body, located_in_admin,
located_near_water, located_on_terrain, location,
location_of_formation, lyrics_by, manufacturer, member_of,
member_of_political_party, member_of_sports_team,
military_branch, mother, mouth_of_watercourse,
narrative_location, notable_work, official_language,
operator, original_language, original_network,
owned_by, parent_organization, parent_taxon,
part_of, participant, participant_in, performer,
place_of_birth, place_of_death, platform, position_held,
producer, production_company, product, publication_date,
```

publisher, record_label, religion, replaced_by, replaces,
 residence, screenwriter, separated_from, series,
 shares_border_with, sibling, spouse, start_time,
 subclass_of, subsidiary, territory_claimed_by,
 twinned_city, unemployment_rate, work_location

IMPORTANT RULES:

- NEVER output 'no_relation', 'none', or 'unknown'.
 Always pick the closest relation.
- For geographic/administrative entities, prefer
 'country', 'located_in_admin', 'contains_admin',
 or 'part_of'.
- 'notable_work' means a creative work (book, film,
 song) by an author/artist. Do NOT use for geographic,
 political, or family relations.
- For family relations, use: 'father', 'mother',
 'child', 'sibling', 'spouse'.

Respond ONLY with JSON:

```
{"relation": "...", "confidence": 0.0-1.0}
```

B Hyperparamètres Ollama Détaillés

TABLE 24 – Hyperparamètres d’inférence Ollama pour chaque tâche.

Paramètre	Extraction	Query	Multi-hop	RAG
Température	0,3	0,3	0,3	0,3
Top-p	0,9	0,9	0,9	0,9
num_ctx	8192	8192	8192	8192
num_predict	1024	2048	4096	2048
Format sortie	JSON	JSON	JSON	Texte + JSON
Timeout (s)	600	600	600	600

Références

- [1] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. Bang, A. Madotto, and P. Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.
- [2] E. Strubell, A. Ganesh, and A. McCallum. Energy and policy considerations for deep learning in NLP. In *Proc. 57th Annual Meeting of the ACL*, pages 3645–3650, 2019.
- [3] Y. Yao, D. Ye, P. Li, X. Han, Y. Lin, Z. Liu, Z. Liu, L. Huang, J. Zhou, and M. Sun. DocRED : A large-scale document-level relation extraction dataset. In *Proc. 57th Annual Meeting of the ACL*, pages 764–777, 2019.

- [4] W.-t. Yih, M. Richardson, C. Meek, M.-W. Chang, and J. Suh. The value of semantic parse labeling for knowledge base question answering. In *Proc. 54th Annual Meeting of the ACL*, pages 201–206, 2016.
- [5] Z. Yang, P. Qi, S. Zhang, Y. Bengio, W. Cohen, R. Salakhutdinov, and C. D. Manning. HotpotQA : A dataset for diverse, explainable multi-hop question answering. In *Proc. EMNLP 2018*, pages 2369–2380, 2018.
- [6] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in NeurIPS*, volume 33, pages 9459–9474, 2020.
- [7] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert. RAGAS : Automated evaluation of retrieval augmented generation. In *Proc. 18th EACL : System Demonstrations*, pages 150–163, 2024.
- [8] W. Zhou, K. Huang, T. Ma, and J. Huang. Document-level relation extraction with adaptive thresholding and localized context pooling. In *Proc. AAAI 2021*, volume 35, pages 14612–14620, 2021.
- [9] Y. Ma, A. Wang, and N. Okazaki. DREEAM : Guiding attention with evidence for improving document-level relation extraction. In *Proc. 17th EACL*, pages 1963–1975, 2023.
- [10] S. Wadhwa, S. Amir, and B. C. Wallace. Revisiting relation extraction in the era of large language models. In *Proc. 61st Annual Meeting of the ACL*, pages 15566–15589, 2023.
- [11] B. Li, G. Fang, Y. Yang, Q. Wang, W. Ye, W. Zhao, and S. Zhang. Evaluating ChatGPT’s information extraction capabilities. *arXiv preprint arXiv :2304.11633*, 2023.
- [12] Y. Ozyurt, S. Feuerriegel, and C. Zhang. Document-level in-context few-shot relation extraction via pre-trained language models. *arXiv preprint arXiv :2310.11085*, 2023.
- [13] P.-L. Huguet Cabot and R. Navigli. REBEL : Relation extraction by end-to-end language generation. In *Findings of EMNLP 2021*, pages 2370–2381, 2021.
- [14] S. Pan, L. Luo, Y. Wang, C. Chen, J. Wang, and X. Wu. Unifying large language models and knowledge graphs : A roadmap. *IEEE Trans. Knowledge and Data Engineering*, 36(7) :3580–3599, 2024.
- [15] Y. Gu, X. Deng, and Y. Su. Don’t generate, discriminate : A proposal for grounding language models to real-world environments. In *Proc. 61st Annual Meeting of the ACL*, pages 4928–4949, 2023.
- [16] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in NeurIPS*, volume 35, pages 24824–24837, 2022.

- [17] A. Lacoste, A. Luccioni, V. Schmidt, and T. Dandres. Quantifying the carbon emissions of machine learning. *arXiv preprint arXiv :1910.09700*, 2019.
- [18] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou. Self-consistency improves chain of thought reasoning in language models. In *Proc. ICLR*, 2023.
- [19] M. Moussaïd, J. E. Kämmer, P. P. Analytis, and H. Neth. Social influence and the collective dynamics of opinion formation. *PLoS ONE*, 8(11) :e78433, 2013.